

Aide-mémoire — Chapitre 4 : Apprentissage non supervisé

BDIA'1 · ENSA Tétouan · Prof. Dr N. Attaoui · Synthèse des notions clés

① Définitions clés & vocabulaire

Apprentissage non supervisé : méthodes travaillant **sans étiquette** (pas de y), uniquement sur X . Objectif : découvrir structures latentes.

3 familles :

- **Clustering** : regrouper des points similaires.
- **Réduction de dimension** : compresser en préservant l'info.
- **Détection d'anomalies** : repérer l'inhabituel.

Partition dure : un point → **un seul** cluster (K-Means, CAH, DBSCAN).

Partition souple (fuzzy) : probabilité d'appartenance à **plusieurs** clusters (GMM).

Centroïde : centre de gravité (moyenne) d'un cluster.

Standardisation : étape quasi obligatoire avant tout algo basé sur la distance.

⚠ **POINT D'ATTENTION** — On n'a pas de « vérité terrain » en non supervisé → on évalue avec des **métriques internes** (silhouette, Davies-Bouldin, Calinski-Harabasz, inertie).

② Distances & similarités

Euclidienne : $d(x,y) = \sqrt{\sum_i (x_i - y_i)^2}$

Manhattan : $d(x,y) = \sum_i |x_i - y_i|$

Minkowski (général) : $d(x,y) = (\sum_i |x_i - y_i|^p)^{1/p}$

Cosinus : $\text{sim}(x,y) = (xy) / (|x||y|)$ — idéal pour le **texte**

✓ **À RETENIR** — Minkowski avec $p=1$ → Manhattan ; $p=2$ → Euclidienne. La cosinus mesure un **angle**, pas une distance géométrique.

③ K-Means (à maîtriser +++)

Principe & algorithme de Lloyd

Objectif : minimiser l'inertie intra-cluster (WCSS)

$J = \sum_{k=1..K} \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$ (problème **NP-difficile** → heuristique)

4 étapes : ① init de K centroïdes (aléatoire ou **K-Means++**) → ② **affectation** de chaque point au centroïde le plus proche → ③ **mise à jour** : μ_k = moyenne du cluster → ④ **convergence** quand les affectations ne bougent plus.

Choix du K

Méthode du coude : tracer inertie vs K, choisir K au « coude » (ralentissement de la baisse).

Silhouette : $s(i) = (b(i) - a(i)) / \max(a(i), b(i))$
avec $a(i)$ =dist. intra moyenne, $b(i)$ =dist. au cluster voisin le plus proche. **s** ∈ [-1, 1]

$s \approx 1$: bien classé · $s \approx 0$: frontière · $s \approx -1$: mal classé. **On choisit le K qui maximise s.**

✓ Avantages	✗ Limites
Simple, rapide, scalable, facile à interpréter.	K à fixer à l'avance .
Converge rapidement.	Sensible à l' initialisation (→ utiliser K-Means++).
K-Means++ : init par défaut dans sklearn.	Clusters forcément sphériques ; sensible aux outliers .

♦ **À COMPRENDRE** — « Pourquoi standardiser avant K-Means ? » → pour éviter qu'une variable à grande échelle (ex. revenu en milliers) ne domine les calculs de distance euclidienne face à une variable à petite échelle (ex. âge).

④ Clustering hiérarchique (CAH)

Principe : construit une **hiérarchie** de clusters représentée par un **dendrogramme**. Pas besoin de fixer K.

Deux approches :

- **Agglomérative (ascendante)** : chaque point = 1 cluster, puis fusions. **Cas le plus fréquent (CAH)**.
- **Divisive (descendante)** : on part d'un cluster unique qu'on divise.

Découpage : coupe horizontale du dendrogramme à une hauteur choisie → nombre de clusters désiré.

Critères de liaison (à connaître) :

Critère	Caractéristique
Single	dist. min. — sensible au bruit, chaînes
Complete	dist. max. — clusters compacts, sensible outliers
Average	moyenne des distances — compromis
Centroid	entre centroïdes — peut produire inversions
Ward	minimise ↑ d'inertie — clusters sphériques équilibrés

⚠ **POINT D'ATTENTION** — Complexité élevée : $O(m^2 \log m)$ à $O(m^3)$ → ne passe **pas à l'échelle** sur gros datasets. Les fusions sont **irréversibles**.

⑤ DBSCAN (clustering par densité)

Idée : un cluster = zone de **haute densité**, séparée de zones de faible densité.

2 paramètres :

- **ε (epsilon)** : rayon de voisinage.
- **MinPts** : nb minimum de voisins pour être « dense ».

3 types de points :

- **Noyau** : ≥ MinPts voisins dans un rayon ε.
- **Frontière** : dans le voisinage d'un noyau, pas noyau lui-même.
- **Bruit** : ni l'un ni l'autre → étiqueté **-1** (= outlier).

✓ Avantages	✗ Limites
-------------	-----------

Pas besoin de fixer K ; détecte clusters de forme arbitraire ; robuste aux outliers (= bruit).	Sensible au choix de ϵ et MinPts ; mauvais avec densités variables ; coûteux en haute dimension.
---	--

⑥ Réduction de dimensionnalité

ACP / PCA (à maîtriser +++)

Matrice de covariance : $C = (1/m) \cdot X^T X$ (sur données **centrées**)
 On cherche les **vecteurs propres** v_i tels que $C \cdot v_i = \lambda_i v_i$, triés par λ **décroissants**.
 Projection : $Z = X \cdot W$ ($W = d$ premiers vecteurs propres).
 Variance expliquée : $VE_k = \lambda_k / \sum_i \lambda_i$ · Seuil pratique : **cumulée $\geq 95\%$** .

Étapes : ① centrer/standardiser → ② calculer C → ③ val. & vect. propres → ④ trier par λ décroissant → ⑤ garder les d premiers → ⑥ projeter.
Conserve la variance globale. Méthode linéaire, déterministe, interprétable.

t-SNE & Auto-encodeurs

Critère	ACP	t-SNE	Auto-encodeur
Projection	Linéaire	Non linéaire	Non linéaire
Préserve	Variance globale	Voisinages locaux	Structure apprise
Déterministe	Oui	Non	Non
Usage	Prétraitement + réduction	Visualisation HD	Réduction + génération
Interprétabilité	Élevée	Faible	Faible
Paramètre clé	d (nb composantes)	perplexité (5–50)	Taille espace latent

✓ **À RETENIR** — Un auto-encodeur **linéaire sans activation** retrouve la même solution que l'ACP → les AE sont une **généralisation non linéaire** de l'ACP.

⚠ **POINT D'ATTENTION** — t-SNE est un **outil de visualisation**, pas de prétraitement. Les résultats dépendent de l'initialisation aléatoire et de la perplexité.

⑦ Détection d'anomalies

Méthode	Principe	Force	Limite
Isolation Forest	Arbres aléatoires ; anomalies isolées en moins de partitions . Score : $s(x) = 2^{-E[h(x)]/c(m)}$; proche de 1 ⇒ anomalie.	Rapide, scalable, haute dim.	Moins précis si densité variable.
LOF (Local Outlier Factor)	Compare la densité locale d'un point à celle de ses k voisins. $LOF \gg 1 \Rightarrow$ anomalie.	Détecte les anomalies locales .	Sensible au choix de k.
DBSCAN (bruit)	Les points non assignés (label -1) sont des anomalies naturelles.	Clustering + anomalies en un seul algo.	Sensible à ϵ et MinPts.
Auto-encodeur	Entraîné sur données « normales » ; une erreur de reconstruction élevée = anomalie.	Adapté aux données complexes (images).	Nécessite entraînement long.

✨ Notions essentielles à maîtriser

Savoir définir & différencier :

- Supervisé vs non supervisé
- Partition dure vs souple
- Métriques internes vs externes
- Noyau / frontière / bruit (DBSCAN)
- ACP vs t-SNE vs auto-encodeur

Savoir écrire / appliquer :

- Formule de l'inertie J (K-Means)
- Formule de la silhouette s(i)
- Les 4 étapes de Lloyd
- Les 6 étapes de l'ACP
- Méthode du coude + silhouette pour K

◆ À COMPRENDRE — Question fréquente : « Quel algo choisir ? » · Clusters **sphériques + K connu** → K-Means · Besoin d'une **structure hiérarchique** → CAH · Formes **arbitraires + outliers** → DBSCAN · **Réduction linéaire** → ACP · **Visualisation 2D** → t-SNE · **Anomalies seules** → Isolation Forest / LOF.