

Aide-mémoire — Chapitre 3 : Classification supervisée

BDIA'1 · ENSA Tétouan · Prof. Dr N. Attaoui · Synthèse des notions clés

① Définitions clés & vocabulaire

Classification = apprentissage supervisé où la cible y est **discrète** (catégorie / classe). Opposé : la **régression** (cible continue).

3 types :

- **Binaire** : 2 classes (spam/non, sain/malade)
- **Multi-classe** : 1 classe parmi K
- **Multi-label** : plusieurs étiquettes par observation

Frontière de décision : surface séparant les classes dans l'espace des features. Peut être linéaire (plan) ou non linéaire.

Objectif central : **généraliser** à de nouvelles données — pas mémoriser les données d'entraînement.

Vocabulaire utile : features (X), label (y), prédiction $\hat{y}$, probabilité $P(y=1|x)$, seuil de décision (souvent 0.5).

② Formulation mathématique

Données : $X \in \mathbb{R}^{m \times n}$ (m observations, n features), $y \in \{0,1\}$ (binaire) ou $\{1..K\}$ (multi-classe).

Modèle : $\hat{y} = f(x)$ — souvent en deux étapes : f estime $P(y=1|x)$, puis règle de seuil.

Décision : $\hat{y} = 1$ si $P(y=1|x) \geq 0.5$, sinon 0.

✓ **À RETENIR** — 3 éléments fondamentaux : X (entrées), y (cibles), f (fonction de décision). Géométriquement, classifier = trouver la frontière qui sépare les classes.

③ Régression logistique (à maîtriser +++)

Principe

Combinaison linéaire $z = w^T x + b$, puis transformation par la **sigmoïde** :

$$\sigma(z) = 1 / (1 + e^{-z}) \in [0,1]$$

$$P(y=1|x) = \sigma(w^T x + b)$$

Frontière de décision linéaire : $w^T x + b = 0$ (correspond à $\sigma = 0.5$).

Fonction coût (log-loss)

$$J(w,b) = -(1/m) \sum [y \log(\hat{y}) + (1-y) \log(1-\hat{y})]$$

Aussi appelée **entropie croisée**. Pénalise très fort les prédictions fausses et confiantes.

Apprentissage : minimiser $J(w,b)$ par **descente de gradient**.

◆ **À COMPRENDRE** — Pourquoi log-loss et pas l'erreur quadratique ? Parce que la sortie est une probabilité $\in [0,1]$: la log-loss pénalise sévèrement la mauvaise calibration (ex. prédire 0.95 alors que $y=0 \rightarrow -\log(0.05) \approx 3$, énorme). C'est crucial en diagnostic médical.

④ Métriques d'évaluation

Matrice de confusion (4 cases)

	Prédit positif	Prédit négatif
Réel positif	VP (vrai positif)	FN (faux négatif)
Réel négatif	FP (faux positif)	VN (vrai négatif)

Métriques dérivées

$$\text{Accuracy} = (VP + VN) / \text{total}$$

$$\text{Precision} = VP / (VP + FP)$$

fiabilité des prédictions positives

$$\text{Recall (sensibilité)} = VP / (VP + FN)$$

capacité à détecter les positifs

$$\text{F1-score} = 2 \cdot (P \cdot R) / (P + R)$$

$$\text{Spécificité} = VN / (VN + FP)$$

Courbe ROC & AUC

La **courbe ROC** trace le recall (TPR) en fonction du **taux de faux positifs** (FPR) pour différents seuils. L'**AUC** (aire sous la courbe) $\in [0, 1]$ résume la qualité globale : plus proche de 1, meilleur le classifieur (0.5 = hasard).

⚠ **POINT D'ATTENTION** — L'**accuracy seule est trompeuse** sur classes déséquilibrées : un modèle prédisant toujours la classe majoritaire peut atteindre 95 % de bonnes réponses sans rien apprendre. Toujours regarder précision, recall et F1 selon le contexte.

⑤ Algorithmes classiques (à comparer)

Algorithme	Idee mathématique	+ Avantage	- Limite
Régression logistique	$z = w^T x + b \rightarrow \sigma(z)$; frontière linéaire	Simple, probabiliste, interprétable	Frontière linéaire seule
KNN	Vote majoritaire des k voisins (distance euclidienne)	Intuitif, sans entraînement (lazy)	Sensible k, échelle, coûteux en prédiction
Arbre de décision	Suite de règles ; minimise Gini = $1 - \sum p_k^2$ ou entropie $H = -\sum p_k \log p_k$	Très interprétable, visualisable	Surapprentissage si trop profond
Forêt aléatoire	Ensemble d'arbres + vote majoritaire ; sous-éch. aléatoires	Robuste, performant, peu de réglage	Moins interprétable, plus coûteux
SVM	Hyperplan $w^T x + b = 0$; maximise la marge ; $\min \frac{1}{2} \ w\ ^2$	Précis quand classes bien séparées	Réglage délicat, lourd sur gros datasets
Naive Bayes	Théorème de Bayes : $P(C x) = P(x C) \cdot P(C) / P(x)$; indép. condit.	Rapide, efficace en haute dim. (texte)	Hypothèse d'indépendance irréaliste

◆ **À COMPRENDRE** — « Quel algo choisir ? » dépend de : taille des données, besoin d'interprétation, nature linéaire/non linéaire, classes équilibrées ou non. **Bonne pratique** : tester plusieurs modèles et comparer leurs métriques sur le même jeu de test.

⑥ Prétraitement & validation

Préparation des données

Étapes courantes : valeurs manquantes, outliers, encodage des qualitatives (label / one-hot), sélection de variables.

Standardisation : $x' = (x - \mu) / \sigma$

Centre les données et égalise les échelles.

Indispensable pour KNN, SVM, régression logistique.

Séparation des données :

- **Train** : ajustement du modèle
- **Validation** : choix des hyperparamètres
- **Test** : évaluation finale (jamais vu avant)

Échantillonnage stratifié : conserve les proportions de classes dans chaque ensemble (essentiel si déséquilibré).

Validation croisée (k-fold)

Divise les données en **k blocs**. À chaque itération : 1 bloc validation, k-1 blocs entraînement. On moyenne les performances → estimation plus **robuste**. La version **stratifiée** conserve les proportions de classes par bloc.

⚠ **POINT D'ATTENTION** — **Fuite de données** (data leakage) = utiliser des informations du test pendant le prétraitement ou le réglage. Conséquence : performances artificiellement gonflées. **Solution** : organiser tout dans un **pipeline** (`Pipeline([scaler, model])`) qui encapsule prétraitement + modèle.

Déséquilibre des classes

Quand une classe domine largement (ex. 95 % vs 5 % en détection de fraude) : ne pas se fier à l'accuracy, privilégier **F1**, **recall**, **AUC**, et utiliser la stratification.

✦ Notions essentielles à maîtriser

Savoir définir & différencier :

- Classification vs régression
- Binaire / multi-classe / multi-label
- VP, VN, FP, FN ; precision vs recall
- Frontière linéaire vs non linéaire
- Train / validation / test

Savoir écrire / appliquer :

- Sigmoid $\sigma(z) = 1/(1+e^{-z})$
- Log-loss $J(w,b)$
- Accuracy, precision, recall, F1
- Standardisation $x' = (x-\mu)/\sigma$
- Gini $= 1 - \sum p_k^2$; théorème de Bayes

◆ **À COMPRENDRE** — **Logique de choix d'une métrique** : Classes équilibrées → accuracy/F1 · Classes déséquilibrées → F1, AUC · Coût élevé d'un faux négatif (ex. médical) → recall · Coût élevé d'un faux positif (ex. spam d'un message important) → precision.

⑦ Pipeline complet — l'ordre à respecter

1. Charger

Importer X, y. Vérifier dimensions, types, valeurs manquantes.

→

2. Séparer

`train_test_split` avec `stratify=y` et `random_state`.

→

3. Pipeline

`StandardScaler` + modèle dans un `Pipeline` (évite la fuite).

→

4. Valider

Validation croisée stratifiée (k=5) sur le train.

→

5. Évaluer

Test final : matrice de confusion + accuracy, F1, AUC.

Tableau récapitulatif — quelle métrique privilégier ?

Contexte applicatif	Métrique principale	Pourquoi ?
Diagnostic médical (cancer, urgence)	Recall, F1	Un faux négatif (malade classé sain) est dramatique → ne pas le manquer
Détection de spam	Precision	Mieux vaut un spam non détecté qu'un mail important classé spam
Détection de fraude (très déséquilibré)	F1, AUC	L'accuracy est trompeuse (99 % de transactions normales)
Classification équilibrée (image, langue)	Accuracy, F1	Toutes les classes ont à peu près la même importance
Comparaison de plusieurs modèles	AUC, F1	Indépendant du seuil, utile pour comparer indépendamment du calibrage