

Aide-mémoire — Ch. 2 : Régression linéaire

BDIA'1 · ENSA Tétouan · Prof. Dr N. Attaoui · Synthèse des notions clés

① Modèle & formulation

Simple : $\hat{y} = w_0 + w_1x$ (droite)

Multiple : $\hat{y} = Xw$ avec $X \in \mathbb{R}^{m \times (n+1)}$, $w \in \mathbb{R}^{n+1}$

Polynomiale : $\hat{y} = w_0 + w_1x + w_2x^2 + \dots$ (créer $x^2, x^3, \dots$ puis rég. lin.)

Le modèle est **linéaire en paramètres** (même si non linéaire en x pour le cas polynomial).

Hypothèses du modèle

Linéarité (relation linéaire $x \leftrightarrow y$) · **Indépendance** des erreurs ·

Homoscédasticité (variance constante) · **Normalité** des résidus · Absence de **multicolinéarité**.

Interprétation géométrique

1 feat. → droite · 2 feat. → plan · n feat. → hyperplan · $\hat{y}$ = projection orthogonale de y sur **Col(X)**. Le résidu $(y - \hat{y})$ est $\perp$ à **Col(X)**.

② Fonction coût & MSE (à maîtriser +++)

$J(w) = (1/m) \sum_i (\hat{y}_i - y_i)^2 = (1/m)(Xw - y)^T(Xw - y)$

Gradient : $\nabla J(w) = (2/m) \cdot X^T(Xw - y)$

Le carré élimine les signes, pénalise les grandes erreurs, et rend J dérivable partout. Sous bruit gaussien, minimiser MSE = maximiser la vraisemblance.

③ Méthodes de résolution

Équation normale (solution analytique)

$w^* = (X^T X)^{-1} \cdot X^T y$

Exact, pas d'hyperparamètre. Mais **O(n³)** → coûteux si n grand.

Problème si $X^T X$ quasi-singulière ou $m < n$.

Descente de gradient

$w := w - \alpha \cdot \nabla J(w)$

$\nabla J = (2/m) \cdot X^T(Xw - y)$

Itératif, scalable. α = learning rate : trop petit → lent, trop grand → diverge. **Standardiser** les features avant !

Variante	Données/itération	+	-
Batch GD	Tout le dataset	Stable	Lent pour grands datasets
SGD	1 échantillon	Rapide, évite minima locaux	Bruité
Mini-batch	Lot de taille B (32-256)	Compromis standard	Hyperparamètre B

◆ **À COMPRENDRE** — **Quand choisir quoi ?** · Petit dataset ($m < 10^4$, $n < 100$) → **équation normale** · Grand dataset ou n élevé → **descente de gradient** (mini-batch). · Toujours : **standardiser** avant la descente de gradient.

④ Types de régression

Type	Nb features	Modèle	Complexité
Simple	1	$\hat{y} = w_0 + w_1x$	Faible
Multiple	$n \geq 2$	$\hat{y} = w_0 + w_1x_1 + \dots + w_nx_n$	Moyenne
Polynomiale	1 (transformée)	$\hat{y} = w_0 + w_1x + w_2x^2 + \dots$	Élevée (risque overfitting)

⚠ **POINT D'ATTENTION** — Plus le degré polynomial augmente, plus le modèle est flexible → **risque de surapprentissage**. La régression polynomiale reste **linéaire en paramètres** (on ajoute x^2, x^3 comme nouvelles colonnes à X).

⑤ Métriques d'évaluation

MSE = $(1/m)\sum(y - \hat{y})^2$ — unité² · pénalise fort les grandes erreurs

RMSE = $\sqrt{\text{MSE}}$ — même unité que y · plus lisible

MAE = $(1/m)\sum|y - \hat{y}|$ — robuste aux outliers

R² = $1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$ — pouvoir explicatif

$R^2=1$ parfait · $R^2=0$ = moyenne · $R^2<0$ = pire que la moyenne

R² ajusté = $1 - [(1-R^2)(m-1)]/(m-n-1)$ — pénalise variables inutiles

✓ **À RETENIR** — MSE pour l'optimisation · RMSE/MAE pour interpréter · R^2 pour le pouvoir explicatif · R^2 ajusté quand on compare des modèles avec différents nombres de variables.

⑥ Régularisation (Ridge / Lasso / Elastic Net)

Méthode	Pénalité ajoutée à J	Sélection var. ?	Solution analytique ?
Ridge (L2)	$\lambda \sum w_i^2$	Non (réduit, n'annule pas)	Oui : $(X^T X + \lambda I)^{-1} X^T y$
Lasso (L1)	$\lambda \sum w_i $	Oui (certains $w_i \rightarrow 0$)	Non (itératif)
Elastic Net	$\lambda_1 \sum w_i + \lambda_2 \sum w_i^2$	Oui	Non

Effet de λ

$\lambda=0$ → pas de régul. (risque overfitting) · λ petit → faible régul. · λ grand Régularisation : ↑ **biais**, ↓ **variance** → meilleure **généralisation**.
→ forte régul. (risque underfitting). Choix optimal par **cross-validation**. Ridge utile si multicolinéarité. Lasso utile si peu de variables importantes.

➔ Notions essentielles à maîtriser

Savoir définir & différencier :

- Régression vs classification
- Simple / multiple / polynomiale
- Équation normale vs descente de gradient
- Batch / SGD / Mini-batch
- Ridge vs Lasso vs Elastic Net
- Biais vs variance, surapprentissage

◆ **À COMPRENDRE** — **Logique de choix** · 1 feature simple → **rég. simple** · Plusieurs features → **rég. multiple** · Relation courbe → **polynomiale** (attention overfitting) · Beaucoup de features, certaines inutiles → **Lasso** · Features corrélées → **Ridge** · Les deux → **Elastic Net**.